RAPPORT

Classification Binaire : Diagnostic Normal vs Surcharge

Objectif de ce rapport
Documenter en detail la conception, l'implementation et l'evaluation d'un systeme de detection binaire (Normal vs Surcharge) sur un moteur DC 12V. Ce rapport couvre deux versions complementaires : une version utilisant des labels physiques realistes et une version utilisant les vrais labels du dataset CSV.

1. Introduction et Objectifs

La surcharge est la cause la plus frequente de defaillance des moteurs a courant continu (DC). Elle se produit lorsque la charge mecanique appliquee sur l'arbre du moteur depasse la capacite nominale, provoquant une augmentation du courant electrique, un echauffement progressif des enroulements et une degradation acceleree de l'isolation.

Ce projet met en oeuvre une classification binaire pour repondre a la question fondamentale du diagnostic : le moteur fonctionne-t-il normalement, ou est-il en etat de surcharge ?

1.1 Capteurs utilises

Capteur	Grandeur	Plage nominale	Role dans la detection de surcharge
Capteur de courant	I (A)	~10 A	Indicateur principal : I augmente sous charge excessive
Capteur de temperature	T (C)	~50 C	Indicateur thermique : T monte progressivement
Capteur de vibration	Vib (u.a.)	~100 u.a.	Indicateur mecanique : vibrations accrues sous contrainte
Capteur de tension	V (V)	~220 V	Surveillance alimentation : chute si probleme electrique

1.2 Definition des classes

Classe	Definition physique	Signatures capteurs
Normal	Moteur en fonctionnement nominal sans anomalie	I ~10A, T ~50C, Vib ~100, V ~220V
Surcharge	Charge mecanique ou thermique excessive provoquant un stress sur le moteur	I eleve, T elevee, Vib accrue, V stable ou legerement basse

1.3 Deux approches complementaires

Version	Fichier	Source des labels	Resultats attendus
Binaire Physique	dc_motor_binary_normal_surcharge.ipynb	Formule mathematique ol_score > 0.6	~95-98% accuracy, AUC ~0.98
Binaire Reels	dc_motor_binary_real_labels.ipynb	Labels reels du CSV (Fault_Status + Fault_Type)	~78% accuracy, AUC ~0.50

2. Dataset et Construction des Labels

2.1 Dataset source

Propriete	Valeur
Fichier	iot_equipment_monitoring_dataset.csv
Nombre total de lignes	50 000
Colonnes utilisees comme features	8 (Temperature, Vibration, Pressure, Voltage, Current, FFT1, FFT2, Anomaly_Score)
Colonnes exclues	Normalized_* (correlation = 1.0 avec les originaux)
Colonnes de labels	Fault_Status (0/1), Fault_Type (NaN / Electrical / Overheating / Mechanical)

2.2 Mapping vers 2 classes — Version Labels Reels

Les labels originaux du dataset comportent 4 types de situations. Pour la classification binaire Normal vs Surcharge, le mapping suivant est applique :

Label original	Classe finale	Action	Justification physique
Fault_Status == 0 (NaN)	Normal	Conserve	Fonctionnement nominal dans toutes les plages
Overheating	Surcharge	Fusionne -> Surcharge	Surchauffe directement liee a une surcharge energetique
Mechanical Failure	Surcharge	Fusionne -> Surcharge	Defaillance mecanique entraine surcharge du courant moteur
Electrical Fault	Exclu	Retire du dataset	Court-circuit = panne differente, hors scope de ce notebook

Pourquoi exclure Electrical Fault ?
Un court-circuit et une surcharge sont deux pannes fondamentalement differentes. Le court-circuit cree un chemin de resistance quasi nulle (spike de courant + chute de tension), tandis que la surcharge est un echauffement progressif par charge excessive. Les inclure dans la meme classe 'Panne' biaise l'apprentissage. On les exclut pour avoir un probleme binaire physiquement coherent.

2.3 Distribution apres mapping (Labels Reels)

Classe	Nombre d'echantillons	Pourcentage	Composition
Normal	34 988	77.8%	Tous les echantillons Fault_Status=0
Surcharge	9 978	22.2%	Overheating (5 028) + Mechanical Failure (4 950)
Total utilise	44 966	100%	50 000 - 5 034 (Electrical Fault exclus)

2.4 Formule de surcharge — Version Labels Physiques

La version physique genere des labels a partir de formules mathematiques representant le comportement reel d'un moteur DC 12V en surcharge.

2.4.1 Valeurs de reference du moteur

Grandeur	Valeur nominale	Ecart-type	Source
Courant I	10.0 A	3.0 A	Calibre nominal du moteur DC 12V
Temperature T	50.0 C	15.0 C	Temperature d'exploitation typique
Vibration Vib	100.0 u.a.	25.0 u.a.	Niveau de vibration nominal
Tension V	220.0 V	10.0 V	Alimentation nominale

2.4.2 Calcul des z-scores

Les z-scores mesurent l'ecart de chaque mesure par rapport a sa valeur nominale :

```
z_I   = (Current     - 10.0) / 3.0     <- ecart normalise du courant
z_T   = (Temperature - 50.0) / 15.0    <- ecart normalise de la temperature
z_Vib = (Vibration   - 100.0) / 25.0   <- ecart normalise de la vibration
```

2.4.3 Score de surcharge et seuil

Le score de surcharge est une combinaison lineaire ponderee des trois z-scores :

```
ol_score = 0.45 * z_I + 0.35 * z_T + 0.20 * z_Vib
Surcharge  si  ol_score > 0.6
Normal     sinon
```

Composante	Poids	Justification
0.45 x z_I	45%	Le courant est le principal indicateur electrique de surcharge
0.35 x z_T	35%	La temperature traduit l'echauffement progressif accumule
0.20 x z_Vib	20%	Les vibrations augmentent sous contrainte mecanique excessive

2.5 Distribution apres formule physique

Classe	Nombre	Pourcentage	Condition
Normal	37 840 - 40 039	~76-80%	ol_score <= 0.6
Surcharge	9 961 - 12 160	~20-24%	ol_score > 0.6

3. Analyse de Separabilite des Features

Avant d'entrainer les modeles, il est essentiel de verifier si les features du dataset permettent de discriminer les deux classes. Un test ANOVA est applique pour mesurer la separabilite statistique.

3.1 Test ANOVA — Labels Reels

Feature	F-statistique	p-value	Signal discriminant ?
Temperature	~0.8	~0.38	NON — distributions identiques
Vibration	~0.9	~0.34	NON — distributions identiques
Pressure	~1.1	~0.29	NON — distributions identiques
Voltage	~0.7	~0.40	NON — distributions identiques
Current	~0.2	~0.66	NON — distributions identiques
FFT_Feature1	~0.4	~0.53	NON — distributions identiques
FFT_Feature2	~1.8	~0.18	NON — distributions identiques
Anomaly_Score	~0.05	~0.82	NON — distributions identiques

Conclusion — Labels Reels
Aucune feature ne permet de distinguer les classes 'Normal' et 'Surcharge' issues du dataset. Les p-values sont toutes superieures a 0.05, confirmant que les distributions des capteurs sont statistiquement identiques entre les deux classes. Le dataset est synthetique avec des labels assignes independamment des valeurs de capteurs. Plafond theorique : Accuracy ~78% (baseline naif), AUC-ROC ~0.50 (aleatoire).

3.2 Separabilite — Labels Physiques

Avec les labels physiques, la separabilite est parfaite par construction : les features Current, Temperature et Vibration sont directement utilisees dans la formule de generation des labels. Un test ANOVA sur ces features donnera des F-statistiques tres elevees et des p-values quasi nulles.

Feature	Separabilite attendue	Raison
Current	Tres elevee	Composante principale du ol_score (poids 0.45)
Temperature	Elevee	Deuxieme composante du ol_score (poids 0.35)
Vibration	Moderee	Troisieme composante du ol_score (poids 0.20)
Voltage, Pressure, FFT*, Anomaly	Nulle	Non incluses dans la formule de surcharge

Conclusion — Labels Physiques
Les labels physiques sont construits directement depuis les features Current, Temperature et Vibration. La separabilite est garantie par construction. Les modeles atteignent 95-98%

d'accuracy et AUC-ROC > 0.98 car ils apprennent precisement les seuils de la formule utilisee pour generer les labels.

4. Pipeline Technique

4.1 Vue d'ensemble

Etape	Labels Reels	Labels Physiques
Chargement	CSV 50 000 lignes	CSV 50 000 lignes
Filtrage	Retrait 5 034 Electrical Fault -> 44 966 lignes	Aucun filtrage
Mapping	Fault_Status + Fault_Type -> Normal / Surcharge	ol_score > 0.6 -> Surcharge
Features	8 features originales (Normalized_* exclues)	8 features originales (Normalized_* exclues)
Split	80% train / 20% test, stratifie	80% train / 20% test, stratifie
Normalisation	StandardScaler (fit sur train uniquement)	StandardScaler (fit sur train uniquement)
Desequilibre	class_weight, sample_weight, undersample	class_weight, sample_weight, undersample
Modeles	RF, HGB, MLP, KNN, SVM, XGBoost + Ensemble	RF, HGB, MLP, KNN, SVM, XGBoost + Ensemble

4.2 Gestion du desequilibre

Les deux versions ont un desequilibre significant (~78/22). Trois strategies sont appliquees :

Algorithme	Strategie	Implementation	Avantage
RF	class_weight='balanced'	Automatique par sklearn	Aucun preprocessing
HGB	class_weight='balanced'	Automatique par sklearn	Efficace et rapide
XGBoost	sample_weight	n_total / (n_classes * n_classe_i)	Equivalent class_weight sans modifier le dataset
MLP	Undersample equilibre	balanced_subsample(5000/classe)	Train rapide, pas de biais de taille
KNN	Undersample equilibre	balanced_subsample(5000/classe)	Seul moyen (pas de class_weight dans KNN)
SVM	Undersample equilibre	balanced_subsample(3000/classe)	SVM O(n^2) : taille limitee pour rapidite

4.3 Metriques d'evaluation specifiques au binaire

Pour la classification binaire, les metriques sont calculees en prenant 'Surcharge' comme classe positive (la classe qu'on cherche a detecter) :

Metrique	Formule	Interpretation pratique
Accuracy	n_correct / n_total	Proportion globale correcte (trompeuse si desequilibre)

Metrique	Formule	Interpretation pratique
F1 Surcharge	2 * P * R / (P + R)	Balance precision et recall sur la detection de surcharge
Precision	TP / (TP + FP)	Parmi les alarmes de surcharge, combien sont reelles ?
Recall	TP / (TP + FN)	Parmi les surcharges reelles, combien sont detectees ?
AUC-ROC	Aire sous la courbe ROC	Capacite de discrimination, independante du seuil de decision

Metrique principale : AUC-ROC

Dans un contexte de diagnostic industriel, l'AUC-ROC est la metrique la plus pertinente car elle mesure la capacite de discrimination sur tous les seuils possibles. Une AUC = 0.5 signifie qu'un modele ne fait pas mieux qu'un tirage aleatoire. Une AUC = 1.0 signifie une discrimination parfaite. Pour la securite industrielle, le Recall est aussi critique : manquer une surcharge (faux negatif) est plus dangereux qu'une fausse alarme (faux positif).

5. Algorithmes Implementes

5.1 Random Forest

Parametre	Valeur	Justification
n_estimators	300	Compromis precision / temps d'execution
max_features	'sqrt'	Reduit la correlation entre les arbres individuels
class_weight	'balanced'	Compense le ratio 78% Normal / 22% Surcharge
Donnees	Train complet (~36 000)	class_weight gere le desequilibre en interne

5.2 HistGradientBoosting (HGB)

Parametre	Valeur	Justification
max_iter	200	Nombre d'iterations de boosting
max_depth	6	Profondeur maximale des arbres
learning_rate	0.1	Taux d'apprentissage modere
min_samples_leaf	30	Evite le surapprentissage sur les feuilles
class_weight	'balanced'	Gestion du desequilibre integree

5.3 MLP (Reseau de Neurones)

Architecture simplifiee pour la classification binaire :

```
Input (8) -> [Dense 64, ReLU] -> [Dense 32, ReLU] -> Output (2, Softmax)
```

Parametre	Valeur	Justification
hidden_layer_sizes	(64, 32)	Architecture allégée (binaire vs multiclasse)
early_stopping	True	Arret si validation stagne (15 iterations)
Donnees	Undersample equilibre 5000/classe	~10 000 total -> train rapide

5.4 KNN (k Plus Proches Voisins)

Parametre	Valeur	Justification
n_neighbors	5	k assez petit pour capter la classe minoritaire
weights	'distance'	Voisins proches ont plus de poids que les lointains
metric	'euclidean'	Distance euclidienne standard sur les features normalisees
Donnees	Undersample equilibre 5000/classe	Seul moyen de gerer le desequilibre pour KNN

5.5 SVM (Support Vector Machine)

Parametre	Valeur	Justification
kernel	'rbf'	Noyau radial pour frontieres de decision non-lineaires
C	10.0	Parametre de regularisation : penalise les erreurs de classification
gamma	'scale'	Calcule automatiquement : 1 / (n_features * X.var())
class_weight	'balanced'	Compense le desequilibre des classes
probability	True	Necessite pour obtenir les probabilites (soft voting)
Donnees	Undersample 3000/classe	SVM RBF = O(n^2) : limite a 6 000 pour rapidite

5.6 XGBoost

Parametre	Valeur	Justification
n_estimators	200	Iterations de boosting
subsample	0.8	80% des lignes par arbre : reduit l'overfitting
colsample_bytree	0.8	80% des features par arbre
reg_alpha / reg_lambda	0.1 / 1.0	Regularisation L1 + L2
sample_weight	Calcule	Equivalent de class_weight pour XGBoost multiclasse

5.7 Ensemble Soft Voting

```
P_ensemble = (P_RF + P_HGB + P_MLP + P_KNN + P_SVM + P_XGB) / 6
Prediction = argmax(P_ensemble)
```

La moyenne des probabilites exploite les forces complementaires de chaque modele. Un modele tres confident sur une prediction equilibre ceux moins certains.

6. Resultats et Comparaison

6.1 Resultats — Version Labels Reels

Resultats attendus (labels independants des features)
Le dataset etant synthetique avec des labels assignes aleatoirement, tous les modeles se comportent comme des classifieurs aleatoires. AUC-ROC ~0.50 pour tous les algorithmes.

Algorithme	Accuracy	F1 Surcharge	Precision	Recall	AUC-ROC
Random Forest	~78%	~0%	~0%	~0%	~0.50
HistGradBoosting	~35%	~variable	variable	variable	~0.50
MLP	~45%	~variable	variable	variable	~0.50
KNN (k=5)	~38%	~variable	variable	variable	~0.50
SVM (RBF)	~35%	~variable	variable	variable	~0.50
XGBoost	~35%	~variable	variable	variable	~0.50
Ensemble (6)	variable	variable	variable	variable	~0.50
Baseline naif	77.81%	0%	0%	0%	0.50

Interpretation des resultats : RF avec class_weight atteint 78% car il predit tout 'Normal' (classe majoritaire). Les autres modeles entraines sur sous-ensembles equilibres obtiennent une accuracy inferieure car ils predisent les deux classes mais le test est domine par 'Normal'. Dans tous les cas, l'AUC-ROC ~0.50 confirme l'absence de signal.

6.2 Resultats — Version Labels Physiques

Resultats attendus (labels coherents avec les features)
Les modeles apprennent la frontiere de decision ol_score = 0.6. Performances elevees garanties par construction.

Algorithme	Accuracy	F1 Surcharge	Precision	Recall	AUC-ROC
Random Forest	~97%	~93%	~95%	~92%	~0.99
HistGradBoosting	~98%	~95%	~97%	~93%	~0.99
MLP	~97%	~93%	~96%	~91%	~0.99
KNN (k=5)	~88%	~78%	~80%	~76%	~0.96
SVM (RBF)	~96%	~91%	~93%	~89%	~0.99
XGBoost	~97%	~94%	~96%	~92%	~0.99
Ensemble (6)	~98%	~95%	~97%	~93%	~0.99

6.3 Comparaison Labels Reels vs Labels Physiques

Critere	Labels Reels	Labels Physiques
Source des labels	Fault_Status + Fault_Type du CSV	Formule ol_score > 0.6

Critere	Labels Reels	Labels Physiques
Accuracy meilleur modele	~78% (RF predit tout Normal)	~98% (Ensemble)
AUC-ROC	~0.50 (aleatoire)	~0.99 (quasi parfait)
F1 Surcharge	~0% (classes non detectees)	~95%
Cause	Dataset synthetique, labels independants des features	Labels generes depuis les features
Validite	Honnete : reflete la realite du dataset	Circularite : modele apprend sa propre formule
Usage recommande	Documentation des limites du dataset	Demonstration de la methodologie ML

7. Analyse des Courbes ROC

La courbe ROC (Receiver Operating Characteristic) trace le taux de vrais positifs (Recall Surcharge) en fonction du taux de faux positifs pour tous les seuils de classification possibles. Elle permet de choisir le meilleur compromis entre detection et fausses alarmes.

7.1 Interpretation de l'AUC-ROC

AUC-ROC	Interpretation	Situation dans ce projet
1.0	Discrimination parfaite (tous les cas corrects)	Labels physiques : Current, T, Vib suffisent
0.9 - 0.99	Excellente discrimination	Labels physiques avec ensemble
0.7 - 0.9	Bonne discrimination	Labels physiques avec KNN
0.5 - 0.7	Discrimination faible	Non atteint dans ce projet
0.5	Equivalent a un tirage aleatoire	Labels reels : tous les algorithmes
< 0.5	Pire qu'aleatoire (possible si classes inversees)	Non atteint

7.2 Lecture pratique de la courbe ROC

Sur la courbe ROC, chaque point correspond a un seuil de probabilite different. Le point optimal est celui qui maximise la distance a la diagonale aleatoire (point en haut a gauche). Pour la detection de surcharge industrielle, on peut choisir un seuil favorisant le Recall (eviter les surcharges non detectees) meme au prix de plus de fausses alarmes.

Strategie	Seuil	Impact	Quand l'utiliser
Maximum F1	~0.5 (defaut)	Equilibre precision et recall	Usage general
Maximum Recall	Seuil bas (~0.2-0.3)	Plus de fausses alarmes, moins de surcharges ratees	Securite : proteger le moteur
Maximum Precision	Seuil haut (~0.7-0.8)	Moins de fausses alarmes mais surcharges ratees	Quand les fausses alarmes sont couteuseuses

8. Structure des Notebooks

8.1 dc_motor_binary_normal_surcharge.ipynb — Labels Physiques (48 cellules)

Section	Contenu
1. Installation	pip install automatique : sklearn, xgboost, matplotlib, seaborn
2. Imports	Ajout de roc_auc_score, roc_curve vs notebooks multiclasses
3. Configuration	Seuil OL_THRESHOLD=0.6, poids W_CURRENT/W_TEMP/W_VIB, valeurs nominales
4. Chargement	Lecture CSV brut
5. Labels physiques	Calcul z-scores + ol_score + assignation + assertion
6. Visualisation	Distribution + histogramme ol_score + scatter Current vs Temperature
7. Features	8 colonnes + LabelEncoder + identification SURCHARGE_IDX
8. Split + Sous-ensembles	80/20, StandardScaler, 3 sous-ensembles + sample_weight XGB
9-14. Entrainement	RF, HGB, MLP (+loss curve), KNN, SVM, XGBoost — chacun avec AUC-ROC
15. Ensemble	Soft voting 6 modeles
16. Confusion matrices	7 matrices 3x3 avec Acc + F1 + AUC dans le titre
17. Courbes ROC	7 modeles sur le meme graphique avec legendes AUC
18. Comparaison	Tableau complet + graphique 4 metriques + graphique AUC separe
19. Feature importance	RF (Gini) + XGBoost cote a cote
20. Sauvegarde	8 fichiers joblib dans outputs_binary/
21. Prediction	predict_surcharge() avec verification par ol_score + 4 scenarios tests

8.2 dc_motor_binary_real_labels.ipynb — Labels Reels (48 cellules)

Section	Contenu
1-3. Setup	Installation, imports identiques, configuration sans parametres physiques
4. Chargement + Mapping	Filtrage Electrical Fault + mapping Overheating/Mechanical -> Surcharge
5. Diagnostic ANOVA	Test statistique prouvant l'absence de signal (p > 0.05 pour toutes les features)
6. Distribution features	Histogrammes superposes montrant les distributions identiques
7-8. Features + Split	Identiques a la version physique
9-14. Entrainement	Memes 6 modeles, parametres identiques
15. Ensemble	Soft voting 6 modeles
16. Confusion matrices	7 matrices + note sur le plafond 78%
17. Courbes ROC	Toutes les courbes proches de la diagonale aleatoire (AUC ~0.50)
18. Comparaison	Tableau + graphique + ligne de baseline 77.81%

Section	Contenu
19. Feature importance	RF Gini (toutes les features ont une importance similaire)
20. Sauvegarde	8 fichiers joblib dans outputs_binary_real/
21. Prediction	predict_surcharge() sans verification physique

9. Comparaison Classification Binaire vs Multiclasse

Critere	Binaire (2 classes)	Multiclasse (3 classes)
Classes	Normal | Surcharge	Normal | Surcharge | Court-Circuit
Labels reels — Accuracy	~78%	~70%
Labels reels — Macro F1	~40-45%	~27-31%
Labels physiques — Accuracy	~97-98%	~97-98%
Metrique principale	AUC-ROC (courbe ROC)	Macro F1 (pas de classe positive)
Complexite du probleme	Plus simple	Plus difficile (3 frontieres)
Utilite pratique	Detection d'anomalie generique	Diagnostic precis du type de panne
Electrical Fault	Exclu (hors scope)	Inclus comme Court-Circuit
Fichiers notebook	2 notebooks (physique + reels)	2 notebooks (v6b + v7)

10. Conclusions et Perspectives

10.1 Bilan de la classification binaire

Deux notebooks complets ont ete produits pour la classification binaire Normal vs Surcharge. Les resultats confirment les conclusions etablies lors de la classification multiclasse : les performances sont directement liees a la qualite des labels utilises.

- Labels physiques : excellents resultats (~98% accuracy, AUC ~0.99) car coherents avec les features
- Labels reels : plafond ~78% avec AUC ~0.50 car le dataset est synthetique
- 6 algorithmes implementes et compares avec metriques binaires adaptees
- Courbes ROC ajoutees comme metrique principale pour le contexte industriel
- Filtrage des Electrical Fault pour un probleme binaire physiquement coherent

10.2 Differences cles avec la classification multiclasse

- Architecture MLP simplifiee (64-32 au lieu de 128-64-32) pour le probleme binaire
- Metrique principale : AUC-ROC au lieu de Macro F1
- Courbes ROC ajoutees pour visualiser le compromis detection / fausses alarmes
- predict_surcharge() affiche les probabilites des 2 classes en temps reel
- Electrical Fault exclu (vs fusionne dans Surcharge en v6b multiclasse)

10.3 Recommandations pour un deploiement industriel

- Utiliser la version labels physiques comme reference de methodologie
- Collecter des donnees reelles avec etiquetage par un expert en maintenance
- Privilegier AUC-ROC et Recall pour la surveillance de securite
- Ajuster le seuil de decision (defaut 0.5) selon les contraintes : securite -> seuil bas, couts -> seuil haut
- Envisager un systeme a deux niveaux : detection binaire (Normal/Panne) puis classification du type

Annexes

A. Fichiers produits

Fichier	Description	Version
dc_motor_binary_normal_surcharge.ipynb	Notebook classification binaire, labels physiques	Physique
dc_motor_binary_real_labels.ipynb	Notebook classification binaire, labels reels	Reels
outputs_binary/rf_model.joblib	RF entraine sur labels physiques	Physique
outputs_binary/hgb_model.joblib	HGB entraine sur labels physiques	Physique
outputs_binary/mlp_model.joblib	MLP entraine sur labels physiques	Physique
outputs_binary/knn_model.joblib	KNN entraine sur labels physiques	Physique
outputs_binary/svm_model.joblib	SVM entraine sur labels physiques	Physique
outputs_binary/xgb_model.joblib	XGBoost entraine sur labels physiques	Physique
outputs_binary/scaler.joblib	StandardScaler ajuste sur le train	Physique
outputs_binary/label_encoder.joblib	LabelEncoder (Normal=0, Surcharge=1)	Physique
outputs_binary_real/rf_model.joblib	RF entraine sur labels reels	Reels
outputs_binary_real/hgb_model.joblib	HGB entraine sur labels reels	Reels
outputs_binary_real/mlp_model.joblib	MLP entraine sur labels reels	Reels
outputs_binary_real/knn_model.joblib	KNN entraine sur labels reels	Reels
outputs_binary_real/svm_model.joblib	SVM entraine sur labels reels	Reels
outputs_binary_real/xgb_model.joblib	XGBoost entraine sur labels reels	Reels

B. Glossaire des metriques binaires

Terme	Definition
TP (Vrai Positif)	Surcharge reelle correctement classee comme Surcharge
TN (Vrai Negatif)	Normal reel correctement classe comme Normal
FP (Faux Positif)	Normal reel incorrectement classe comme Surcharge (fausse alarme)
FN (Faux Negatif)	Surcharge reelle incorrectement classee comme Normal (surcharge ratee)
Precision	TP / (TP + FP) : qualite des alarmes de surcharge
Recall (Sensibilite)	TP / (TP + FN) : taux de detection des surcharges reelles
F1-Score	Moyenne harmonique de Precision et Recall

Terme	Definition
AUC-ROC	Aire sous la courbe ROC : probabilite que le modele classe une surcharge avant un normal
Specificite	TN / (TN + FP) : taux de detection correct des cas normaux
Seuil de decision	Probabilite minimale pour classer 'Surcharge' (defaut 0.5, ajustable)

C. Differences techniques entre les deux notebooks binaires

Element	Labels Physiques	Labels Reels
Filtrage	Aucun (50 000 lignes)	Retrait Electrical Fault (44 966 lignes)
Section 2	Formules z-scores + seuil OL_THRESHOLD	Mapping Fault_Status + Fault_Type
Section 3	Visualisation scores et scatter plot	Test ANOVA + histogrammes superposes
Cellule prediction	Affiche ol_score + comparaison attendu vs predit	Affiche probabilites seulement
OUTPUT_DIR	outputs_binary/	outputs_binary_real/
Donnees train taille	~40 000	~35 973
AUC-ROC attendu	~0.98-0.99	~0.50